


## Support Vector Machine



Model ที่ใช้จำแนกประเภทข้อมูล (Classification) โดยสร้าง hyperplane ขึ้นมาเพื่อจำแนกข้อมูลออกจากกัน

**Hyperplane**  
เพื่อหาให้ได้ระยะห่าง ระหว่าง 2 Class มากรสุด  
โดยหาจาก Lagrange Multipliers (LM), Karush Kuhn Tucker (KKT)

$X_1$	$X_2$	...	$X_D$	$Y$
$x_1^1$	$x_1^2$	...	$x_1^D$	$y_1$
$x_2^1$	$x_2^2$	...	$x_2^D$	$y_2$
$x_3^1$	$x_3^2$	...	$x_3^D$	$y_3$
:	:	:	:	:
$x_N^1$	$x_N^2$	...	$x_N^D$	$y_N$

**X** คือ ตัวแปรต้น (**Feature**)

**Y** คือ ตัวแปรตาม (**Target**)

**N** คือ จำนวนตัวอย่างทั้งหมด

**D** คือ จำนวน **Feature** ทั้งหมด


**Ex.**


$Data =$

อายุ	น้ำหนัก	ເມານວາ?
34	50	ໄຟເປັນ
25	90	ເປັນ
62	70	ເປັນ
53	85	ເປັນ
27	65	ໄຟເປັນ
42	55	ໄຟເປັນ

(+,-)

$$X = \begin{bmatrix} 34 & 50 \\ 25 & 90 \\ 62 & 70 \\ 53 & 85 \\ 27 & 65 \\ 42 & 55 \end{bmatrix}, Y = \begin{bmatrix} \text{ໄຟເປັນ} \\ \text{ເປັນ} \\ \text{ເປັນ} \\ \text{ເປັນ} \\ \text{ໄຟເປັນ} \\ \text{ໄຟເປັນ} \end{bmatrix}$$





อายุ	จำนวน	เมรัววน?
45	90	?

$$y_{\text{predict}} = \text{sgn}(0.045x_1 + 0.083x_2 - 7.65)$$


$$y_{\text{predict}} = \text{sgn}(0.045(45) + 0.083(90) - 7.65)$$

$$y_{\text{predict}} = \text{sgn}(1.845)$$

$$y_{\text{predict}} = +1$$

อายุ	จำนวน	เมรัววน?
45	90	เป็น

## Lagrange Multipliers (LM)





$$\text{จำนวนเนิ่งบวก} = 1^2 + 1^2 + 1^2 + 1^2$$

$$99 = 9^2 + 4^2 + 1^2 + 1^2$$

ความชัน = อัตราการเปลี่ยนแปลง x,y => Diff  
(ความชันใหญ่ที่คงที่ หรืออัตราการเปลี่ยนแปลง)  
[ปรับ W คือ ปรับความชัน]

เลขยกกำลัง 2 ลีดี้ จะทำกับจำนวนเนิ่งบวก (Lagrange)  
ทุกจำนวนสามารถทำในสมการนี้ได้




(ให้ความชันรายตัว)

$$W = W - \alpha \frac{\text{Error}}{\gamma w}$$

$$\begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_3 \end{bmatrix} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_3 \end{bmatrix} - \begin{bmatrix} \frac{\partial \text{Error}}{\partial w} \\ \vdots \\ \frac{\partial \text{Error}}{\partial w} \end{bmatrix}$$

ความชันในทุกมิติ  
(ให้ความชันหลาย ตัว)





$$W = W - \nabla \text{Error}$$

Gradient

Gradient มาช่วยคำนวณ => LM

3 มิติ



ความชันไม่เท่า  
ไปในแนวเดียวกัน

Gradient function

$$\nabla f(x, y) = 0$$

(2) ณ จุดสัมผัสกัน ความชัน (Slope) & เกรดิエンต์ (Gradient สนามเวกเตอร์) อยู่ในทิศทางเดียวกัน  
หรือตรงข้ามกันได้ (ความชันไม่เท่ากัน)  
แต่จะพุ่งออกจากจุดเดียวกัน


ดังนั้น จึงสร้างตัวแปรขึ้นมาอีกด้วย  
เป็นค่าที่บ่งบอกถึงอัตราส่วนของขนาดของเวกเตอร์ทั้งสอง  
**Lagrange Multipliers (LM)**

Gradient  $\nabla$  ใช้ทั้งสอง เพราะไปในแนวเดียวกัน

$$\nabla f(x, y) = -\lambda \nabla g(x, y)$$

แรมต้าติดลบ เพื่อจัดรูปง่าย  
เวลา y หายข้าง = 0

## Lagrange Multipliers (LM)



$$\nabla f(x, y) \text{ อยู่ในระนาบเดียวกัน } \nabla g(x, y)$$

$$\nabla f(x, y) \underset{\text{แปรผัน}}{\propto} \nabla g(x, y)$$

$$\nabla f(x, y) = -\lambda \nabla g(x, y) \quad \text{เวลา y น้อยกว่าจะได้ตัดกันง่าย}$$

$$\therefore \nabla f(x, y) + \lambda \nabla g(x, y) = \emptyset$$

$$\nabla f(x, y) + \sum_{i=1}^M \nabla g_i(x, y) = \emptyset$$

หา  $x, y$  ต่ำสุดได้

step1

$$\nabla (f(x, y) + \lambda g(x, y)) = \emptyset$$

$$L = f(x, y) + \lambda g(x, y)$$

step2

$$\nabla L = \emptyset \quad \left\{ \frac{\partial L}{\partial x}, \frac{\partial L}{\partial y} \right\} = \emptyset$$

ให้  $x, y$  ไว้คิด

$\lambda$

step3

แทน  $x, y$  ลงใน constrain  $g(x, y)$  เพื่อหา  $\lambda$

step4

แทนค่า  $x, y$  และ  $\lambda$  ในสมการ  $f(x, y)$  ก็จะได้จุดต่ำสุด  $x, y$  ของมา

การคำนวณแบบ

## ตัวอย่างคำนวณ Lagrange Multipliers (LM)

Ex1.

$$\text{objective function : } f(x, y) = x^2 + y^2 \\ \text{subject to : } g(x, y) = 4x + 3y - 12 = 0$$

### 1) หา Lagrange Function

$$\nabla f(x, y) = -\lambda \nabla g(x, y)$$


$$\nabla f(x, y) + \lambda \nabla g(x, y) = \emptyset$$

$$\nabla (f(x, y) + \lambda g(x, y)) = \emptyset$$

↙  $L = f(x, y) + \lambda g(x, y)$

$$L = x^2 + y^2 + \lambda (4x + 3y - 12)$$

$$\nabla L = \emptyset$$



Gradient function

$$\nabla f(x, y) = \mathbf{0}$$

<https://www.geogebra.org/3d?lang=th>

	$f(x, y) = x^2 + y^2$		⋮
	$\text{eq1: } 4x + 3y - 12 = 0$		⋮
+	ค่าน่าเข้า...		

2) คำนวณ  $\nabla L = \emptyset \rightarrow \frac{\partial L}{\partial x}, \frac{\partial L}{\partial y} \quad | \quad L = x^2 + y^2 + \lambda (4x + 3y - 12)$

$$\frac{\partial L}{\partial x} = 2x + 4\lambda$$

$$\emptyset = 2x + 4\lambda$$

$$x = -2\lambda$$

$$\frac{\partial L}{\partial y} = 2y + 3\lambda$$

$$\emptyset = 2y + 3\lambda$$

$$y = -\frac{3\lambda}{2}$$

3) แทนค่า  $x, y$  ลงใน constraint  $\Rightarrow g(x,y)$  เพื่อคำนวณ  $\lambda$

$$g(x,y) = 4x + 3y - 12 = 0$$

$$4(-2\lambda) + 3\left(-\frac{3\lambda}{2}\right) - 12 = 0$$

$$-8\lambda - \frac{9\lambda}{2} - 12 = 0$$

$$\frac{-16\lambda - 9\lambda}{2} - 12 = 0$$

$$-\frac{25\lambda}{2} = 12$$


$$\lambda = -\frac{24}{25}$$

4) คำนวณ  $x, y$  จาก  $\lambda$

$$\Rightarrow x = -2\lambda, \quad y = \frac{-3\lambda}{2}, \quad \lambda = \frac{-24}{25}$$

$$\begin{aligned} x &= -2 \left( \frac{-24}{25} \right) \\ &= \frac{48}{25} \end{aligned} \quad \mid \quad \begin{aligned} y &= \frac{-3}{2} \left( \frac{-24}{25} \right) \\ &= \frac{36}{25} \end{aligned}$$

จุดต่อสุดที่สัมผัส  $(x, y)$




$$\therefore f(x, y) = x^2 + y^2$$

$$= \left( \frac{48}{25} \right)^2 + \left( \frac{36}{25} \right)^2$$

$$= \frac{2304}{625} + \frac{1296}{625} = \frac{3600}{625}$$

$$= \frac{144}{25}$$

ระยะ





⚠  $G(x, y) = \left( \frac{48}{25} \right)^2 + \left( \frac{36}{25} \right)^2$

⚠  $f(x, y) = x^2 + y^2$

●  $eq1 : 4x + 3y - 12 = 0$

Ex 2.

objective function :  $f(x, y) = x + 2y + 20$   
subject to :  $g(x, y) = x^2 + y^2 - 16 = 0$



### 1) 用 Lagrange Function

$$\nabla f(x, y) = -\lambda \nabla g(x, y)$$

$$\nabla f(x, y) + \lambda \nabla g(x, y) = \emptyset$$

$$\nabla (f(x, y) + \lambda g(x, y)) = \emptyset$$

↙  $L = f(x, y) + \lambda g(x, y)$

$$L = x + 2y + 20 + \lambda(x^2 - y^2 - 16)$$

$$\nabla L \neq \emptyset$$

	$f(x, y) = x + 2y + 20$	⋮
	$\text{eq1: } x^2 + y^2 - 16 = 0$	⋮

2) คำนวณ  $\nabla L = \emptyset \rightarrow \frac{\partial L}{\partial x}, \frac{\partial L}{\partial y}$

$$L = x + 2y + 20 + \lambda(x^2 - y^2 - 16)$$

$$\begin{aligned} \frac{\partial L}{\partial x} &= 1 + 2\lambda x \\ \frac{\partial L}{\partial y} &= 2 + 2\lambda y \\ x &= -\frac{1}{2\lambda} \end{aligned} \quad \left| \begin{array}{l} \frac{\partial L}{\partial y} = 2 + 2\lambda y \\ 0 = 2 + 2\lambda y \\ y = -\frac{2}{2\lambda} = -\frac{1}{\lambda} \end{array} \right.$$

3) แทนค่า  $x, y$  ลงใน constraint  $\Rightarrow g(x, y)$  เพื่อคำนวณ  $\lambda$

$$g(x, y) = x^2 + y^2 - 16 = 0$$

$$\left( \frac{-1}{2\lambda} \right)^2 + \left( \frac{-1}{\lambda} \right)^2 - 16 = 0$$

$$\frac{1}{4\lambda} + \frac{4}{4\lambda} = 16$$

$$\frac{5}{4\lambda^2} = 16$$

$$\lambda^2 = \frac{5}{64}$$

$$\lambda = \pm \frac{\sqrt{5}}{8}$$


4) คำนวณ  $x, y$  จาก  $\lambda$

$$\text{Case1} \quad \lambda = \frac{\sqrt{5}}{8}, \quad x = -\frac{1}{2\lambda}, \quad y = -\frac{1}{\lambda}$$

$$\begin{aligned} x &= -\frac{1}{2} \div \frac{\sqrt{5}}{8} \\ &= -\frac{1}{2} \times \frac{8}{\sqrt{5}} \\ &= -\frac{4}{\sqrt{5}} \end{aligned} \quad \begin{aligned} y &= -1 \div \frac{\sqrt{5}}{8} \\ &= -1 \times \frac{8}{\sqrt{5}} \\ &= -\frac{8}{\sqrt{5}} \end{aligned}$$

$$\text{Case2} \quad \lambda = -\frac{\sqrt{5}}{8}$$

$$x = \frac{4}{\sqrt{5}}, \quad y = \frac{8}{\sqrt{5}}$$



แทนค่าหา min,max จาก  $f(x,y)$


$$f(x,y) = x + 2y + 20$$

$$\text{Case1} \quad -\frac{4}{\sqrt{5}} + 2\left(-\frac{8}{\sqrt{5}}\right) + 20$$

$$= -\frac{20}{\sqrt{5}} + 20 \quad \text{min}$$


$$\text{Case2} \quad \frac{4}{\sqrt{5}} + 2\left(\frac{8}{\sqrt{5}}\right) + 20$$

$$= \frac{20}{\sqrt{5}} + 20 \quad \text{max}$$



<span style="color: lightblue;">●</span>	$f(x, y) = x + 2y + 20$	⋮
<span style="color: red;">●</span>	$\text{eq1: } x^2 + y^2 - 16 = 0$	⋮
<span style="color: magenta;">●</span>	$E(x, y) = -\frac{4}{\sqrt{5}} - 2 \cdot \frac{8}{\sqrt{5}} + 20$	⋮


**min**



<span style="color: lightblue;">●</span>	$f(x, y) = x + 2y + 20$	⋮
<span style="color: red;">●</span>	$\text{eq1: } x^2 + y^2 - 16 = 0$	⋮
<span style="color: yellow;">●</span>	$G(x, y) = \frac{4}{\sqrt{5}} + 2 \cdot \frac{8}{\sqrt{5}} + 20$	⋮

**max**






$$\nabla f(x, y) = -\lambda \nabla g(x, y)$$

$$1) \nabla L = \emptyset$$

$$2) g(x, y) = \emptyset$$

KKT



ดูเป็นพื้นที่  
ไม่ได้ทำ " = " ได้เสมอ  
 $\Leftrightarrow \lambda \geq 0$

min

$$\nabla f(x, y) = -\lambda \nabla g(x, y)$$


max

$$\nabla f(x, y) = \lambda \nabla g(x, y)$$

แก้ปัญหารูปทรงแบบ convax (เลขคณิต)



Yes  
ใช้ได้กับ KKT ได้



No

convex = สมการลากเส้นจากจุด 2  
จุดที่สัมผัสดู ไปได้ในพื้นที่เดียวกัน

### กฎและเงื่อนไข (KKT)

1) Stationarity  $\nabla L(x, \lambda, \mu) = \emptyset \Rightarrow \nabla L = \emptyset$


2) Primal feasibility  $\begin{cases} g_i(x) \leq 0 \\ h_i(x) = 0 \end{cases} \Rightarrow g(x, y) \leq 0$


3) Dual feasibility  $\mu_i \geq 0 \Rightarrow \mu \geq 0$

เพื่อให้ได้ค่า Max / ค่า Min  
ก็ต้องสัมผัสน้ำหนัก


4) Complementary slackness  $\mu_i g_i(x) = 0 \Rightarrow \underline{\mu^* g(x, y) = 0}$

Global Point (G)






Top View




Objective function จุดค่าสัมบูรณ์ / สูงสุดของ  
คือจุด Global Point (G)



$$\nabla f(x, y) = 0$$

$$M = \emptyset$$

$$g(x, y) \neq 0$$



$$M \neq \emptyset$$

$$g(x, y) = 0$$

step1  $\nabla (f(x,y) + \mu g(x,y)) = \emptyset$

$$L = f(x,y) + \mu g(x,y)$$

step2  $\nabla L = \emptyset \quad \left\{ \frac{\partial L}{\partial x}, \frac{\partial L}{\partial y} \right\} = \emptyset$  ได้  $x, y$  ไข่คิด  $M$

step3 แทน  $x, y$  ลงใน Objective function ( $L$ )

ติดค่า  $M$

รูปแบบ Dual From  $\rightarrow (LM)$

step4 แทนค่า  $x, y$  ใน Constraint  $g(x,y)$  เพื่อหา Objective function ใน Dual From  $\Rightarrow$  ได้  $M$


step5 ค่าใน  $\nabla L$  (ของ Dual From)  $\left\{ \frac{\partial L}{\partial M} = \frac{\eta \text{ (สมการ } L \text{ ใน step3)}}{\partial M}$

แทนค่า  $x, y$  ในสมการ  $L$  (step 3)



## Karush Kuhn Tucker

Ex1.

$$\begin{aligned} & \text{minimize :} && f(x, y) = (x - 3)^2 + (y - 4)^2 \\ & \text{subject to :} && g(x, y) = x^2 + y^2 - 100 \leq 0 \end{aligned}$$



$$\mathcal{M} = \emptyset$$



### 1) หา Lagrangian Function

$$\nabla f(x, y) = -\lambda \nabla g(x, y)$$

$$\nabla f(x, y) + \lambda \nabla g(x, y) = \emptyset$$

$$\nabla (f(x, y) + \lambda g(x, y)) = \emptyset$$

$$L = f(x, y) + \lambda g(x, y)$$

$$\therefore L = (x - 3)^2 + (y - 4)^2 + \lambda(x^2 + y^2 - 100)$$

$$\nabla L = \emptyset$$

2) คำนวณ  $\nabla L = \emptyset$

หาจุดต่ำสุดแบบหัวๆไป

$$\begin{array}{|c|c|} \hline \frac{\partial f(x,y)}{\partial x} = 0 & \frac{\partial f(x,y)}{\partial y} = 0 \\ \hline 2(x-3) = 0 & 2(y-4) = 0 \\ x = 3 & y = 4 \\ \hline \end{array}$$

$$\frac{\partial L}{\partial x} = 2(x-3) + 2mx$$

$$0 = 2(x-3) + 2mx$$

$$0 = x-3+mx$$

$$mx+x = 3$$

$$x(m+1) = 3$$

$$x = \frac{3}{m+1}$$

$$\frac{\partial L}{\partial y} = 2(y-4) + 2my$$

$$0 = y-4+my$$

$$my+y = 4$$

$$y(m+1) = 4$$

$$y = \frac{4}{m+1}$$

3) แทนค่า  $x, y$  ลงใน  $L$  เพื่อหา Objective function ( $L$ ) ใน Dual Form

$$x = \frac{3}{M+1}$$

$$y = \frac{4}{M+1}$$

$$\begin{aligned}
 \therefore L &= (x-3)^2 + (y-4)^2 + M(x^2 + y^2 - 100) \\
 &= \left(\frac{3}{M+1} - 3\right)^2 + \left(\frac{4}{M+1} - 4\right)^2 + M \left[ \left(\frac{3}{M+1}\right)^2 + \left(\frac{4}{M+1}\right)^2 - 100 \right] \\
 &= 3^2 \left(\frac{1}{M+1} - 1\right)^2 + 4^2 \left(\frac{1}{M+1} - 1\right)^2 + M \left[ \frac{25}{(M+1)^2} - 100 \right] \\
 &= 25 \left(\frac{1}{M+1} - 1\right)^2 + \frac{25}{(M+1)^2} - 100M \\
 \text{---}^{-(M+1)} \curvearrowright &= 25 \left(\frac{1-M-1}{M+1}\right)^2 + \frac{25M}{(M+1)^2} - 100M \\
 &= \frac{25M^2}{(M+1)^2} + \frac{25M}{(M+1)^2} - 100M
 \end{aligned}$$

$$= \frac{25M^2 + 25M}{(M+1)^2} - 100M$$

$$= \frac{25M(M+1)}{(M+2)^2} - 100M$$

$$= \frac{25M}{M+1} - 100M$$

$$= \frac{25M - 100M(M+1)}{M+1}$$

$$= \frac{25M - 100M^2 - 100M}{M+1}$$

$$L = \frac{-100M^2 - 75M}{M+2} \quad \text{\# Dual Form}$$

4) แทนค่า  $x, y$  ลงใน constraint ( $g(x,y)$ ) เพื่อหา Objective function ใน Dual Form

$$x = \frac{3}{\mu+1}$$

$$y = \frac{4}{\mu+1}$$

$$\therefore x^2 + y^2 - 100 \leq 0$$

$$\left(\frac{3}{\mu+1}\right)^2 + \left(\frac{4}{\mu+1}\right)^2 - 100 \leq 0$$

$$\frac{9}{(\mu+1)^2} + \frac{16}{(\mu+1)^2} \leq 100$$

$$\frac{25}{(\mu+1)^2} \leq 100$$

$$25 \leq 100(\mu+1)^2$$

$$\frac{1}{4} \leq (\mu+1)^2$$


หารด้วย 100

$$(\mu+1)^2 - \frac{1}{4} \geq 0$$

$$4\mu^2 + 8\mu + 3 \geq 0$$

$$(2\mu+3)(2\mu+1) \geq 0$$

$$\mu = -\frac{3}{2}; -\frac{1}{2} \text{ # KKT } \mu \geq 0$$



$$\mu \in (-\infty, -\frac{3}{2}] \cup [-\frac{1}{2}, \infty)$$

$\mu \in [0, \infty)$  # คำตกลง  
 $\mu = 0 \Rightarrow \infty$

5) คำนวณ  $\nabla L = 0$  (L จากขั้นตอนที่ 3) ของ Dual Form

$$L = \frac{100M^2 - 75M}{M+2}$$

ล่างดีฟบัน ลม บันเดิฟล่า  
ส่วนด้วยลงกานลังส่อง

$$\frac{\frac{8L}{\pi M}}{1} = \frac{(M+1) \circ (-100M^2 - 75M)}{8M} - \frac{(-100M^2 - 75M)}{8M} \frac{8(M+1)}{(M-1)^2}$$

$$\theta = \frac{(M+1)(-200M-75) + (100M^2 + 75M)}{(M-1)^2} (1)$$

$$b = (n+2)(x - 200n - 75) + 100n^2 + 75n$$

$$= -200u^2 - 75u - 200u - 75 + 100u^2 + 75u$$

$$= -100\mu^2 - 200\mu - 75$$

$$= 100 \mu^2 + 200 \mu + 75$$

$$= 411^2 + 3m + 1$$

$$= (2n+3)(2n+1)$$

ล่างดิฟบัน ลบ บันดิฟล่า  
ส่วนด้วยล่างกำลังสอง

$$+ 100u^2 + 75u$$

KKT ມີມາດຈຸກ

$$\therefore u = \frac{-3}{2} \text{ or } -\frac{1}{2}$$

$u \geq 0$


$$\therefore u = 0$$

ແກນຕົດໃນ  $x, y$  ຈາກຂັ້ນດອນທີ 2

$x = \frac{3}{u+1}$ $= 3$	$y = \frac{4}{u+1}$ $= 4$
------------------------------	------------------------------

Ex1.

minimize :  $f(x, y) = (x - 3)^2 + (y - 4)^2$   
subject to :  $g(x, y) = x^2 + y^2 - 4 \leq 0$



### 1) หา Lagrangian Function

$$\nabla f(x, y) = -\lambda \nabla g(x, y)$$

$$\nabla f(x, y) + \lambda \nabla g(x, y) = \emptyset$$

$$\nabla (f(x, y) + \lambda g(x, y)) = \emptyset$$

$$L = f(x, y) + \lambda g(x, y)$$

$$\therefore L = (x - 3)^2 + (y - 4)^2 + \lambda(x^2 + y^2 - 4)$$

$$\nabla L = \emptyset$$

2) คำนวณ  $\nabla L = \emptyset$

$$\frac{\partial L}{\partial x} = 2(x-3) + 2mx$$

$$0 = 2(x-3) + 2mx$$

$$0 = x - 3 + mx$$

$$mx + x = 3$$

$$x(m+1) = 3$$

$$x = \frac{3}{m+1}$$

$$\frac{\partial L}{\partial y} = 2(y-4) + 2my$$

$$0 = y - 4 + my$$

$$my + y = 4$$

$$y(m+1) = 4$$

$$y = \frac{4}{m+1}$$

3) แทนค่า  $x, y$  ลงใน  $L$  เพื่อหา Objective function ( $L$ ) ใน Dual Form

$$\therefore L = (x-3)^2 + (y-4)^2 + M(x^2 + y^2 - 4)$$

$$= \left( \frac{3}{M+1} - 3 \right)^2 + \left( \frac{4}{M+1} - 4 \right)^2 + M \left[ \left( \frac{3}{M+1} \right)^2 + \left( \frac{4}{M+1} \right)^2 - 4 \right]$$
$$= 3^2 \left( \frac{1}{M+1} - 1 \right)^2 + 4^2 \left( \frac{1}{M+1} - 1 \right)^2 + M \left[ \frac{9}{(M+1)^2} + \frac{16}{(M+1)^2} - 4 \right]$$

$$= 25 \left( \frac{1}{M+1} - 1 \right)^2 + \frac{25}{(M+1)^2} - 4M$$


$$= 25 \left( \frac{1-M-1}{M+1} \right)^2 + \frac{25M}{(M+1)^2} - 4M$$

$$= \frac{25M^2}{(M+1)^2} + \frac{25M}{(M+1)^2} - 4M$$

$$= \frac{25M^2 + 25M}{(M+1)^2} - 4M$$

$$= \frac{25M(M+1)}{(M+2)^2} - 4M$$

$$= \frac{25M}{M+1} - 4M$$

$$= \frac{25M - 4M(M+1)}{M+1}$$

$$= \frac{25M - 4M - 4M^2}{M+1}$$

$$L = \frac{21M - 4M^2}{M+2} \quad \text{Dual Form}$$

ทำต่อขั้นตอน 5

4) แทนค่า  $x, y$  ลงใน constraint ( $g(x,y)$ ) เพื่อหา Objective function ใน Dual Form

$$\therefore x^2 + y^2 - 4 \leq 0$$

$$\left(\frac{3}{m+1}\right)^2 + \left(\frac{4}{m+1}\right)^2 - 4 \leq 0$$

$$\frac{9}{(m+1)^2} + \frac{16}{(m+1)^2} \leq 4$$

$$\frac{25}{(m+1)^2} \leq 4$$

$$25 \leq 4(m+1)^2$$

$$\frac{25}{4} \leq (m+1)^2$$

$$0 \leq (m+1)^2 - \frac{25}{4}$$

$$0 \leq 1 + 2m + m^2 - \frac{25}{4}$$


$$0 \leq 4 + 8m + 4m^2 - 25$$

$$0 \leq 4m^2 + 8m - 21$$

$$0 \leq (2m+7)(2m-3)$$

$$(2m+7)(2m-3) \geq 0$$

$$m = -\frac{7}{2}; \quad \frac{3}{2} \text{ # KKT } m \geq 0$$



$$m \in (-\infty, -\frac{7}{2}] \cup [\frac{3}{2}, \infty)$$

$$m \in [\frac{3}{2}, \infty) \text{ # คำตกลง } \}$$

5) คำนวณ  $\nabla L = 0$  ( $L$  จากขั้นตอนที่ 3) ของ Dual Form

$$L = \frac{21\mu - 4\mu^2}{\mu+1}$$

$$\frac{\partial L}{\partial \mu} = \frac{(\mu+1)(-3\mu+21) - (-4\mu^2+21\mu)(1)}{(\mu+1)^2}$$

$$\varnothing = \frac{-3\mu^2 + 21\mu - 8\mu + 4\mu^2 - 21\mu + 21\mu}{(\mu+1)^2}$$

$$\varnothing = \frac{-4\mu^2 - 8\mu + 21\mu}{(\mu+1)^2}$$

$$4\mu^2 + 8\mu - 21 = 0$$

$$\mu \text{ ต้อง } \mu = \frac{3}{2}$$

แทนตัดใน  $x, y$  จากขั้นตอนที่ 2

$$\begin{aligned} x &= \frac{3}{\mu+1} \\ &= \frac{6}{5} \end{aligned}$$

$$\begin{aligned} y &= \frac{4}{\mu+1} \\ &= \frac{8}{5} \end{aligned}$$

$$\mu = -8 \pm \sqrt{\frac{8^2 - (4)(4)(-21)}{2(4)}} \quad \left[ \begin{array}{l} \frac{-8+20}{8} = 3/2 \\ \frac{-8-20}{8} = -7/2 \end{array} \right]$$

$$(\mu-1)^2 \rightarrow ①$$


KKT หมายความ  $\mu \geq 0$

$$\mu = -\frac{7}{2}; \quad \left( \frac{3}{2} \right) \text{ # KKT } \mu \geq 0$$

Duplicate a(x,y)


X = 6/5 , Y = 8/5

<span style="color: blue;">●</span>	$a(x, y) = (x - 3)^2 + (y - 4)^2$	⋮
<span style="color: red;">●</span>	$b(x, y) = x^2 + y^2 - 4$	⋮
<span style="color: purple;">●</span>	$c(x, y) = \left(\frac{6}{5} - 3\right)^2 + \left(\frac{8}{5} - 4\right)^2$	⋮
<span style="color: black;">+</span>	ค่านำเข้า...	



## Support Vector Machine

เส้นแบ่งสองกลุ่มให้ได้ระยะ  
ห่างมากที่สุด = Error



$$\text{Margin (M)} \Rightarrow \vec{w}$$

subject to

$$y_i (\vec{w} \vec{x} + b) \geq 1$$

เรารอ想找 Hyper Plane ที่ทำให้ Margin ห่างมากสุด


$$w_1 x_1 + w_2 x_2 + \dots + w_b x_b + b = 0$$

$x$  เป็นค่าคงที่ รั้วจากข้อมูล Data set


Hyper Plane



จุดที่ใกล้ที่สุดเรียกว่า Support Vector



จุด SVM = จุดที่ใกล้เส้น Hyperplane



สิ่งที่รู้

$$\vec{w} \cdot \vec{r}_2 + b = 1$$

$$\vec{w} \cdot \vec{r}_1 + b = -1$$

ห่างขนาด M  
(Margin) ได้

$$M = \|\vec{w}\| \cos \theta$$

$$M = \|\vec{r}_2 - \vec{r}_1\| \cos \theta$$

จากมุม

$$\vec{A} \cdot \vec{B} = \|\vec{A}\| \times \|\vec{B}\| \times \cos \theta$$

$$\therefore M = \|\vec{r}_2 - \vec{r}_1\| \times \|\vec{w}\| \times \cos \theta$$


$$= (\vec{r}_2 - \vec{r}_1) \cdot \vec{w}$$

จาก

$$\begin{aligned}
 M &= \|\vec{r}_2 - \vec{r}_1\| \cdot 1 \cdot \cos \theta \\
 &= \|\vec{r}_2 - \vec{r}_1\| \cdot \|\vec{w}\| \cdot \cos \theta \\
 &= (\vec{r}_2 - \vec{r}_1) \cdot \vec{w} \\
 &= (\vec{r}_2 - \vec{r}_1) \cdot \frac{\vec{w}}{\|\vec{w}\|}
 \end{aligned}$$

เขียนขนาด M  
ให้อยู่ในรูป เวกเตอร์  
 $\vec{w}$  ได้

Note เวกเตอร์ 1 หน่วยแนวนอนจาก



เวกเตอร์ 1  
หน่วยตั้งจาก


สูตร

$$\begin{aligned}
 \vec{OP} &= \vec{OQ} + \vec{QP} \\
 &= \vec{x}_i + \vec{y}_j \\
 &= [x] \quad \text{or} \quad (x, y) \\
 &\therefore \frac{\vec{w}}{\|\vec{w}\|} \neq
 \end{aligned}$$

$$\|\vec{w}\| = \sqrt{w_1^2 + w_2^2 + \dots + w_d^2}$$

ค่าคงที่  
 $\frac{1}{\|\vec{w}\|}$

พิสูจน์




$$\vec{OV} = \vec{ai} + \vec{bj} + \vec{ck}$$

$$\vec{w} \cdot \vec{x} = 0$$

$$A \cdot B = \|A\| \times \|B\| \times \cos(\theta)$$

$$= \emptyset$$



$$\vec{P}_1 = x_p \hat{i} + y_p \hat{j} + z_p \hat{k}$$

$$\vec{P} = x \hat{i} + y \hat{j} + z \hat{k}$$

$$\vec{P} - \vec{P}_1 = (x - x_p) \hat{i} + (y - y_p) \hat{j} + (z - z_p) \hat{k}$$

$$\vec{OV} \times (\vec{P} - \vec{P}_1) = \emptyset \quad \text{ดังนั้น}$$

$$a(x - x_p) + b(y - y_p) + c(z - z_p) = \emptyset$$

$$ax + by + cz - ax_p - by_p - cz_p = \emptyset$$

$$ax + by + cz = ax_p + by_p + cz_p$$

$$w_1 x_1 + w_2 x_2 + \dots + w_p x_p = -b$$

$$\vec{n} = \frac{\vec{OV}}{\|\vec{w}\|} = \frac{\vec{w}}{\|\vec{w}\|}$$

ต้องทำให้ขนาดของ(ตัวส่วน)  $\|\vec{w}\|$  น้อยสุด เพื่อให้ได้ M มากสุด

$$\left. \begin{array}{l} M = \max \\ \text{เมื่อ } \vec{w} = \min \end{array} \right\} \text{(KKT)}$$

$$\vec{w} \cdot \vec{x} + b = \emptyset \Rightarrow \vec{w} \cdot \vec{x} = -b$$

$$\vec{OV} = \vec{w}$$

จึงได้

minimize

$$\|\vec{w}\|$$

subject to

$$y_i (\vec{w} \vec{x} + b) \geq 1$$

$$\|\vec{w}\| = \sqrt{w_1^2 + w_2^2 + \dots + w_D^2}$$

เพื่อให้ง่ายต่อการ diff

$$\|\vec{w}\|^2$$

เพื่อไม่ให้มีเศษส่วน

$$\frac{1}{2} \|\vec{w}\|^2$$

subject to

$$y_i (\vec{w} \vec{x} + b) \geq 1$$

กรณีไม่มี Error

$$\text{ชาย } \mathcal{E} = \emptyset$$

กรณีมี Error

$$\mathcal{E} \neq \emptyset$$

$$y_i (\vec{w} \vec{x} + b) \geq 1$$

$$y_i (\vec{w} \vec{x} + b) \geq 1 - \frac{1-y_i (\vec{w} \vec{x} + b)}{\mathcal{E}}$$


$$\therefore y_i (\vec{w} \vec{x} + b) \geq 1 - \mathcal{E}$$

กรณีที่มี error  
จึงได้


$$\text{minimize}_{\vec{w}} \frac{1}{2} \|\vec{w}\|^2 + \left( \sum_{i=1}^n \xi_i \right)$$

$$\frac{1}{2} \|\vec{w}\|^2 + \underbrace{\left( \sum_{i=1}^n \xi_i \right)}_{\text{เพื่อลดความ Overfit}}$$

$$\therefore \xi_i = \max [0, 1 - y_i (\vec{w} \cdot \vec{x} + b)]$$




1) ถ้าอยู่ต่อกัน [0 , ติดลบ]  $\Rightarrow [0 , 1 - (\text{เลขมากกว่าเท่ากับ } 1)]$



อยู่ติดกัน เป็น support vector



2) ถ้าอยู่ผิดฟัง ระหว่าง margin [0 , บวก]  $\Rightarrow [0 , 1 - (\text{เลขบวกกว่า } 1)]$



3) ถ้าอยู่ผิดฟัง [0 , บวก]  $\Rightarrow [0 , 1 - (\text{น้อยกว่า } \text{ไม่เท่ากัน } 1)]$

Error จำนวนมาก

จงได้

minimize

$$\frac{1}{2} \|\vec{w}\|^2 + \sum_{i=1}^N \xi_i$$

subject to

$$y_i (\vec{w} \cdot \vec{x}_i + b) \geq 1 - \xi_i$$

เมื่อ

$$\xi_i \geq 0$$

จัดรูปใหม่

minimize

$$\frac{1}{2} \|\vec{w}\|^2 + \sum_{i=1}^N \xi_i$$

subject to

$$1 - \xi_i - y_i (\vec{w} \cdot \vec{x}_i + b) \leq 0$$

เมื่อ

$$-\xi_i \leq 0$$

Lagrangan fuction  $\nabla f(w_1, w_2, \dots, w_D, \xi_1, \xi_2, \dots, \xi_N) = - \sum_{i=1}^N \alpha_i \nabla g_i(b, w_1, w_2, \dots, w_D, \xi_i) - \sum_{i=1}^N \beta_i \nabla h_i(\xi_i)$

KKT

Dud From (SVM)

maximize

$$\sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \vec{x}_i \cdot \vec{x}_j$$

subject to

$$\sum_{i=1}^N \alpha_i y_i = 0$$

เมื่อ

$$0 \leq \alpha_i \leq C$$

เมื่อ Data มีมากกว่า Feature  
ทำให้หา Inver ไม่ได้  
หรือเกิด Overfit จึงต้องใช้  
SMO เข้ามาช่วย



## สวัสดี Sequential Minimal Optimization (SMO) Algorithm

แก้ปัญหา Time complexity  
ของ SVM  $O(n^3) \Rightarrow SMO$   
อยู่ในช่วงระหว่าง  $O(n^2)$

$$\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \vec{x}_i \cdot \vec{x}_j$$

SMO จะมีการอัปเดทค่า  $\alpha$  ข้อมูล 2 จุด ( $\alpha_i$  ตัวตั้งต้น ไม่ได้ถูกเลือกให้เป็นค่าคงที่), ( $\alpha_j$  ที่ถูกเลือก)

subject to

$$y_i(\vec{w} \cdot \vec{x}_i + b) \geq 1$$

สรุปสมการที่ใช้ใน SMO

1) Update  $\alpha_b$  : เมื่อ(eta)

$$\alpha_j$$

$$E_i = \vec{w} \cdot \vec{x}_i + b - y_i$$

$$\eta = 2k_{ab} - k_{aa} - k_{bb}$$

$$= 2\vec{x}_i \cdot \vec{x}_j - \vec{x}_i \cdot \vec{x}_i - \vec{x}_j \cdot \vec{x}_j$$

$$\text{new } \alpha_b = \alpha_b^{\text{old}} - \frac{\eta_b (E_a^{\text{old}} - E_b^{\text{old}})}{\eta}$$

ไม่เท่ากับ 0  
ถ้าเป็น 0  
ต้องสูบใหม่

2) ห้ามอนใหม่  
(Clip)

ให้  $L, H$  เป็นขอบล่าง  
และขอบบน

ถ้า

$$\begin{cases} y_a = y_b \\ (y_i = y_j) \end{cases} \quad L = \max(0, \alpha_i + \alpha_j - C) \\ H = \min(C, C + \alpha_j - \alpha_i)$$

ถ้า

$$\begin{cases} y_a \neq y_b \\ (y_i \neq y_j) \end{cases} \quad L = \max(0, \alpha_j - \alpha_i) \\ H = \min(C, C + \alpha_j - \alpha_i)$$



เข้าสู่การเงื่อนไขเพื่ออัปเดต

new,Clipped  
 $\alpha_b$

i = a  
j = b

new,Clipped

เข้าสมการเงื่อนไขเพื่ออัปเดท

$$\alpha_b$$

new,Clipped

$$\alpha_b$$

$$\alpha_j$$

$$\left\{ \begin{array}{l} L ; \alpha_b^{\text{new}} < L \\ \alpha_b^{\text{new}} ; L \leq \alpha_b^{\text{new}} \leq H \\ H ; \alpha_b^{\text{new}} > H \end{array} \right.$$


---

3) Update  $\alpha_a$   
( $\alpha_i$ ; ตัวเริ่มต้น)


$$\begin{aligned} \alpha_a^{\text{new}} &= \alpha_a^{\text{old}} + \gamma (\alpha_b^{\text{old}} - \alpha_b^{\text{new}}) \\ &= \alpha_i^{\text{old}} + \gamma (\alpha_i^{\text{old}} - \alpha_v^{\text{new}}) \end{aligned}$$


---

$$\gamma = y_i y_j = Y_a Y_b$$

4)

4) Update (b) ในสีอกค่าระหว่าง  $\alpha_a$  และ  $\alpha_b$  ว่าอยู่ในช่วง  $(0, C)$  ไม่รวมจุดตันและปลาย



แต่ถ้าอยู่ในช่วง  $(0, C)$  ทั้งคู่ ( $\alpha_a = \alpha_b$ ) ในหน้ามาเลี้ยกัน

$$\frac{b_a + b_b}{2}$$

$$b = \begin{cases} b_a & ; \quad 0 < \alpha_a < c \\ b_b & ; \quad 0 < \alpha_b < c \\ \frac{b_a + b_b}{2} & ; \text{ otherwise} \end{cases}$$

$$b_i^{\text{new}} = b_i^{\text{old}} - E_i^{\text{old}} - (\alpha_i^{\text{new}} - \alpha_i^{\text{old}}) y_i \vec{x}_i \cdot \vec{x}_i - (\alpha_j^{\text{new}} - \alpha_j^{\text{old}}) y_j \vec{x}_i \cdot \vec{x}_j$$

$$b_j^{\text{new}} = b_j^{\text{old}} - E_j^{\text{old}} - (\alpha_i^{\text{new}} - \alpha_i^{\text{old}}) y_i \vec{x}_j \cdot \vec{x}_j - (\alpha_i^{\text{new}} - \alpha_i^{\text{old}}) y_i \vec{x}_i \cdot \vec{x}_j$$

5) Update (W : weight)


$$W = W + \frac{\text{new}}{\text{old}} \alpha_a y_a \times a + \frac{\text{new}}{\text{old}} \alpha_b y_b \times b$$

$$= W + \frac{\text{old}}{\text{new}} (\alpha_i^{\text{new}} - \alpha_j^{\text{old}}) y_i \vec{x}_i + \frac{\text{new}}{\text{old}} (\alpha_j^{\text{new}} - \alpha_i^{\text{old}}) y_i \times j$$

EX

Index	X1	X2	Y
1	1	1	1
2	2	1	1
3	2	2	1
4	-1	-2	-1
5	-2	-1	-1
6	-2	-2	-1

เวลาดูข้อมูล [1 1] => มองเป็น Vector  $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$



กำหนดให้

$$C = 1 \quad b = 0$$

$$W = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

C แปรผันกับ Hard Margin  
(C มาก Overfit ได้)

1) ค่ารวม  $E_i = \vec{w} \cdot \vec{x}_i + b - y_i$  สุ่มเลือกเอา Index ที่ 1

$$E_i = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} + 0 - 1 = -1$$

มองอยู่ในรูป Vector = [ ดัง ]

2) ค่ารวม  $E_j = \vec{w} \cdot \vec{x}_j + b - y_j$  สุ่มเลือกเอา Index ที่ 3

$$E_j = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \begin{bmatrix} 2 \\ 2 \end{bmatrix} + 0 - 1 = -1$$

Dot product

$$\begin{bmatrix} 1 \\ 3 \end{bmatrix} \cdot \begin{bmatrix} 5 \\ 7 \end{bmatrix} = [(1 \times 3) + (3 \times 7)] = 26$$

3) ค่าน้ำวน(eta)  $\eta = 2\vec{x}_i \cdot \vec{x}_j - \vec{x}_i \cdot \vec{x}_i - \vec{x}_j \cdot \vec{x}_j$

$$= 2\vec{x}_1 \vec{x}_3 - \vec{x}_1 \vec{x}_1 - \vec{x}_3 \vec{x}_3$$

$$= 2 \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 2 \\ 2 \end{bmatrix} - \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \begin{bmatrix} 2 \\ 2 \end{bmatrix} \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

$$\eta = (2 \times 4) - 2 - 8 = -2 \quad \#$$


---

4) หาขอบล่างของ  $\alpha_j$  จาก  $y_i^{\textcolor{red}{1}} = y_j^{\textcolor{red}{1}} \Rightarrow L = \max (\emptyset, \alpha_i + \alpha_j - c)$

$$= \max (\emptyset, 0 - 2) \Rightarrow -1 \quad \#$$

0 มีค่ามากกว่า -1  
เลือกตัวน้อยสุด

5) หาขอบบนของ  $\alpha_j$  จาก  $y_i^{\textcolor{blue}{1}} = y_j^{\textcolor{blue}{1}} \Rightarrow H = \min (\emptyset, \alpha_i + \alpha_j)$

$$= (1, 0 + 0) \Rightarrow 0 \quad \#$$

1 มีค่ามากกว่า 0  
เลือกตัวน้อยสุด

6) update  $\alpha_j^{\text{new}} = \alpha_j^{\text{old}} - \frac{y_j(E_i - E_j)}{n}$

$$\alpha_j^{\text{new}} = \emptyset - \frac{1[(-1) - (-1)]}{-2} = \emptyset \quad \#\!$$


---

7) clip  $\alpha_j^{\text{new}}$

$$\left\{ \begin{array}{ll} L; & \alpha_b^{\text{new}} < L \\ \alpha_b^{\text{new}}; & L \leq \alpha_b^{\text{new}} \leq H \\ H; & \alpha_b^{\text{new}} > H \end{array} \right.$$

$L = -1, \alpha_j = \emptyset, H = \emptyset$

$$\therefore \alpha_v^{\text{new}} = \emptyset$$


---

8) update  $\alpha_i^{\text{new}} = \alpha_i^{\text{old}} + \gamma(\alpha_j^{\text{old}} - \alpha_j^{\text{new}})$

$$= \emptyset + 1(0 - 0) = \emptyset$$

$$\gamma = y_a y_b = (1)(1) = 1$$

$$\gamma = y_i y_j = (1)(1) = 1$$

9) คำนวณ

$$\begin{aligned}
 b_i &= b_{\text{old}} - \mathbb{E}_i - (\alpha_i^{\text{new}} - \alpha_i^{\text{old}}) y_i \vec{x}_i \cdot \vec{x}_i - (\alpha_j^{\text{new}} - \alpha_j^{\text{old}}) y_j \vec{x}_i \cdot \vec{x}_j \\
 &= \theta - (-1) - (\theta - \theta)(1) \begin{bmatrix} 1 \\ 1 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 1 \end{bmatrix} - (\theta - \theta)(1) \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 2 \\ 2 \end{bmatrix}
 \end{aligned}$$

$$b_i = 1 \quad \#$$


---

10) คำนวณ

$$\begin{aligned}
 b_j &= b_{\text{old}} - \mathbb{E}_j - (\alpha_j^{\text{new}} - \alpha_j^{\text{old}}) y_j \vec{x}_{ji} \cdot \vec{x}_j - (\alpha_i^{\text{new}} - \alpha_i^{\text{old}}) y_i \vec{x}_j \cdot \vec{x}_j \\
 &= \theta - (-1) - (\theta - \theta)(1) \begin{bmatrix} 2 \\ 2 \end{bmatrix} \cdot \begin{bmatrix} 2 \\ 2 \end{bmatrix} - (\theta - \theta)(1) \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 2 \\ 2 \end{bmatrix}
 \end{aligned}$$

$$b_j = 1 \quad \#$$


---

11) update b

$$b = \begin{cases} b_i & ; \alpha_i \in (0, \zeta), \alpha_j \notin (0, \zeta) \\ & 0 < \alpha_i < \zeta \\ b_j & ; \alpha_i \notin (0, \zeta), \alpha_j \in (0, \zeta) \\ & 0 < \alpha_j < \zeta \\ \frac{b_i + b_j}{2} & ; \text{otherwise (หาค่าเฉลี่ยทั้งสองตัว)} \end{cases}$$

$$b = \begin{cases} b_a & ; 0 < \alpha_a < \zeta \\ b_b & ; 0 < \alpha_b < \zeta \\ \frac{b_a + b_b}{2} & ; \text{otherwise} \end{cases}$$

$$\therefore \alpha_i = 0, \alpha_j = 0 \\ b_i = 1, b_j = 1 \quad \left. \begin{array}{l} \text{อยู่ข้างเดียวกันทั้งคู่} \Rightarrow \text{จึงหาค่าเฉลี่ย} \\ \frac{b_i + b_j}{2} = \frac{1+1}{2} = 1 \end{array} \right\} \#$$

12) update W

$$\begin{aligned} w^{\text{new}} &= w^{\text{old}} + (\alpha_i^{\text{new}} - \alpha_i^{\text{old}}) y_i \vec{x}_i + (\alpha_j^{\text{new}} - \alpha_j^{\text{old}}) y_j \vec{x}_j \\ &= [0] + (0 - 0)(1) \begin{bmatrix} 1 \\ 2 \end{bmatrix} + (0 - 0)(1) \begin{bmatrix} 2 \\ 2 \end{bmatrix} \\ &= 0 \Rightarrow \begin{bmatrix} 0 \\ 0 \end{bmatrix} \# \end{aligned}$$

ผลลัพธ์คำนวณรอบแรก  $w = 0, b = 1$

ผลลัพธ์รอบสอง     $E_i = 0, E_j = 2, \eta = -20, H = 1, L = 0, \alpha_j = 0.1, \alpha_i = 0.1$   
 $b_i = 1, b_j = -1, b = \emptyset$       สุมเลือก index 2 ตัว =>  $i = 2, j = 5$  (index ที่ 2, 5)

$$\begin{aligned}
 \vec{w} &= \vec{w}^{\text{old}} + (\alpha_2^{\text{new}} - \alpha_2^{\text{old}}) y_2 \vec{x}_2 + (\alpha_5^{\text{new}} - \alpha_5^{\text{old}}) y_5 \vec{x}_5 \\
 &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} + (0.1 - 0) (1) \begin{bmatrix} 2 \\ 1 \end{bmatrix} + (0.1 - 0) (-1) \begin{bmatrix} -2 \\ -1 \end{bmatrix} \\
 &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} + 0.2 \begin{bmatrix} 2 \\ 1 \end{bmatrix} - 0.1 \begin{bmatrix} -2 \\ -1 \end{bmatrix} \\
 &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 0.2 \\ 0.1 \end{bmatrix} + \begin{bmatrix} 0.2 \\ 0.1 \end{bmatrix} \\
 &= \begin{bmatrix} 0.4 \\ 0.2 \end{bmatrix} \quad \cancel{\text{not}}
 \end{aligned}$$

## - Code SVM (SMO) -

1) คำนวณ  $E_i = \vec{w} \cdot \vec{x}_i + b - y_i$  และ  $E_j = \vec{w} \cdot \vec{x}_j + b - y_j$

```
def SVM_compute_E(W, x_train, b, y):
    E = np.dot(x_train, W) + b - y
    return E
```

---

2) คำนวณ(eta)  $\eta = 2\vec{x}_i \cdot \vec{x}_j - \vec{x}_i \cdot \vec{x}_i - \vec{x}_j \cdot \vec{x}_j$

เปลี่ยนจาก dot เป็น product ใช้ kernel


```
def SVM_compute_eta(xi, xj, kf):
    eta = 2*kernel(xi, xj, kf) - kernel(xi, xi, kf) - kernel(xj, xj, kf)
    return eta
```

```

def kernel(xi, xj, kf):
    if kf[0] == 'Dot':
        return np.dot(xi, xj)
    elif kf[0] == 'Polynomial':
        p = kf[1]
        return (np.dot(xi, xj) + 1)**p
    elif kf[0] == 'RBF':
        gamma = kf[1]
        degree = np.sum((xi - xj)**2)
        return np.e**(-gamma*degree)

```

RBF (เรเดียนเบลิกฟังก์ชัน) : จะ diff  
จำนวนที่ดีที่สุด แบ่งให้ได้ Feature ที่เหมาะสม



3) หาข้อมูล่างของ  $\alpha_i$  จาก

$$y_i = y_j \quad L = \max(\emptyset, \alpha_i + \alpha_j - C)$$

$$y_i \neq y_j \quad L = \max(\emptyset, \alpha_j - \alpha_i)$$

```

def SVM_compute_L(yi, yj, C, alpha_i, alpha_j):
    if yi == yj:
        L = max([0, alpha_i + alpha_j - C])
    elif yi != yj:
        L = max([0, alpha_j - alpha_i])
    return L

```

4) หาขอบล่างของ  $\alpha$  จาก

$$y_i = y_j \quad H = \min(\mathcal{C}, \mathcal{C} + \alpha_j - \alpha_i)$$
$$y_i \neq y_j \quad H = \min(\mathcal{C}, \mathcal{C} + \alpha_j - \alpha_i)$$

```
def SVM_compute_H(yi, yj, C, alpha_i, alpha_j):
    if yi == yj:
        H = min([C, alpha_i + alpha_j])
    elif yi != yj:
        H = min([C, C + alpha_j - alpha_i])
    return H
```

5) หา  $\alpha_j^{\text{new}}$

```
def SVM_compute_alpha_j(alpha_j, yj, Ei, Ej, eta, L, H):
    new_alpha_j = alpha_j - yj*(Ei - Ej)/eta
    if new_alpha_j < L:
        new_alpha_j = L
    elif new_alpha_j > H:
        new_alpha_j = H
    return new_alpha_j
```

$$\left\{ \begin{array}{l} L ; \alpha_b^{\text{new}} < L \\ \alpha_b ; L \leq \alpha_b^{\text{new}} \leq H \\ H ; \alpha_b^{\text{new}} > H \end{array} \right.$$

### 6) update b

$$b = \begin{cases} b_i & \text{if } \alpha_i \in (0, C), \alpha_j \notin (0, C) \\ & 0 < \alpha_i < C \\ b_j & \text{if } \alpha_j \notin (0, C), \alpha_i \in (0, C) \\ & 0 < \alpha_j < C \\ \frac{b_i + b_j}{2} & \text{otherwise (หาค่าเฉลี่ยทั้งสองตัว)} \end{cases}$$

$$b_i = b_{\text{old}} - E_i - (\alpha_i^{\text{new}} - \alpha_i^{\text{old}}) y_i \vec{x}_i \cdot \vec{x}_i - (\alpha_j^{\text{new}} - \alpha_j^{\text{old}}) y_j \vec{x}_i \cdot \vec{x}_j$$

$$b_j = b_{\text{old}} - E_j - (\alpha_j^{\text{new}} - \alpha_j^{\text{old}}) y_j \vec{x}_j \cdot \vec{x}_j - (\alpha_i^{\text{new}} - \alpha_i^{\text{old}}) y_i \vec{x}_j \cdot \vec{x}_j$$

```
def SVM_compute_b(b, Ei, Ej, new_alpha_i, old_alpha_i, new_alpha_j, old_alpha_j, yi, xi, yj, xj, C, kf):
    bi = b - Ei - (new_alpha_i - old_alpha_i)*yi*kernel(xi, xi, kf) - (new_alpha_j - old_alpha_j)*yj*kernel(xi, xj, kf)
    bj = b - Ej - (new_alpha_j - old_alpha_j)*yj*kernel(xj, xj, kf) - (new_alpha_i - old_alpha_i)*yi*kernel(xi, xj, kf)
    is_sv_i = (new_alpha_i > 0) and (new_alpha_i < C)
    is_sv_j = (new_alpha_j > 0) and (new_alpha_j < C)
    if is_sv_i and not is_sv_j:
        new_b = bi
    elif not is_sv_i and is_sv_j:
        new_b = bj
    else:
        new_b = (bi + bj)/2
    return new_b
```

9) คำนวณ  $b_i$

10) คำนวณ  $b_j$

7) Run ทั้งหมด  
(พยากรณ์)

```
def SVM_fit(X_Train, Y_Train, C, kf, max_iteration = 1000):
    N = X_Train.shape[0]
    D = X_Train.shape[1]
    alpha = np.zeros(N)
    W = np.zeros(D)
    b = 0
    for e in range(max_iteration):
        two_dots_index = random.sample(range(N), 2)
        i = two_dots_index[0]
        xi = X_Train[i, :]
        yi = Y_Train[i, 0]
        j = two_dots_index[1]
        xj = X_Train[j, :]
        yj = Y_Train[j, 0]
        Ei = SVM_compute_E(W, xi, b, yi)
        Ej = SVM_compute_E(W, xj, b, yj)
        eta = SVM_compute_eta(xi, xj, kf)
        if eta >= 0:
            continue
        L = SVM_compute_L(yi, yj, C, alpha[i], alpha[j])
        H = SVM_compute_H(yi, yj, C, alpha[i], alpha[j])
        new_alpha_j = SVM_compute_alpha_j(alpha[j], yj, Ei, Ej, eta, L, H)
        new_alpha_i = alpha[i] + yi*yj*(alpha[j] - new_alpha_j)
        b = SVM_compute_b(b, Ei, Ej, new_alpha_i, alpha[i], new_alpha_j, alpha[j], yi, xi, yj, xj, C, kf)
        W = W + (new_alpha_i - alpha[i])*yi*xi + (new_alpha_j - alpha[j])*yj*xj
        alpha[i] = new_alpha_i
        alpha[j] = new_alpha_j
    return W, b, alpha
```

12) update W

## 7) ท่านาย Predict (Test)

```
def SVM_predict(X_Test, W, b):
    Zhat_Test = np.dot(X_Test, W) + b
    Yhat_Test = np.sign(Zhat_Test)
    return Yhat_Test.reshape(-1, 1)
```

$\vec{W}\vec{X} + b = 0$   
 $X / \sqrt{X^* X}$   
$$\begin{bmatrix} \cdot \\ \cdot \\ \cdot \\ \cdot \end{bmatrix}$$
  
row ไม่กำหนด  
column = 1